前馈重建前端如何接入 3D 高斯泼溅：VGGT / VGGT-Ω 位姿与内参的一次性束调整精化

Bending Feed-forward Reconstruction into 3D Gaussian Splatting: One-shot Bundle Adjustment for VGGT / VGGT-Ω Pose and Intrinsics

宗炜
zongwave@hotmail.com

摘 要：前馈式三维重建网络（VGGT、VGGT-Ω）单次前向即可同时输出相机、深度与稠密点图，其推理速度比基于特征匹配的增量式结构恢复（COLMAP）快数倍，因而被认为是可替代后者的重建前端。然而当我们把这两类前端接入同一条 3D 高斯泼溅（3DGS）训练管线并严格控制变量时，前馈网络的结果在留出视角上比 COLMAP 低 4.4–7.5 dB。本文把这一差距完整归因到相机位姿与内参而不是初始点云：（i）网络位姿存在相干性系统偏差，旋转残差中位数 1.29°（VGGT）与 0.54°（VGGT-Ω），而 COLMAP 解之间的一致性约为 0.04°；（ii）网络从不估计镜头畸变（$k_1 \equiv 0$），焦距系统性偏长 +2.6%，使得在原始畸变图像上训练时重投影模型整体失配。据此我们提出并在国产 AI 加速器（天数 BI-V150S，CoreX-5.0）上验证一条极简精化链路（路线 **A**）：复用生产链路已有的 SIFT 二维观测，在冻结的网络位姿下做一次三角化，再做一次全局束调整（并夹一轮点过滤），从而同时修复位姿与内参；网络自身的稠密点图不参与任何残差。在一个 83 帧、留出 11 视角、共 20 个档位的同配置干净矩阵上：本文链路把 VGGT-Ω 从 21.35 dB 提到 25.79 dB（口径 A）与从 21.74 dB 提到 26.72 dB（口径 B），与 COLMAP 全流程的 25.77 dB / 26.82 dB 打平（LPIPS 更优，0.198 vs 0.203）；VGGT 收回 +5.12 dB，残余 -1.13 dB。旋转残差同时降到 0.0701°（Ω）与 0.3212°（VGGT），畸变从无到有（k_1=-0.0133，参照 -0.0148）。我们进一步给出三条反直觉结论：把网络自己的稠密点图接回 3DGS 初始化会损失 2.8–3.2 dB；用网络自点图自建轨迹做"自证式"束调整虽然重投影残差最低（0.256 px）却使位姿更歪（1.29°→1.43°），即束调整的全部收益来自与网络无关的独立对应；把第 1 轮束调整迭代上限从 100 降到 30，解逐位相同而墙钟从 142 s 降到 57 s。最后我们澄清了成本结构：COLMAP 的束调整并非单次昂贵，而是被增量式建图反复调用（实测 35 次全局 +≈81 次局部，累计 ≈97 s，占 mapper 墙钟 53%）；本文把它降级为推理末尾的一次求解，成本线性于观测数，但同时诚实地指出——加上这一步之后，前馈前端的速度优势基本被吃平（VGGT ≈144 s vs COLMAP 149 s；VGGT-Ω ≈211 s）。

关键词：前馈式三维重建；VGGT；VGGT-Ω；3D 高斯泼溅；束调整；结构恢复；COLMAP；神经渲染

Key words: feed-forward 3D reconstruction; VGGT; VGGT-Ω; 3D Gaussian splatting; bundle adjustment; structure-from-motion; COLMAP; neural rendering

1 引言

3D 高斯泼溅（3DGS）[1] 的重建质量由两件事决定：输入图像的覆盖，以及作为优化起点的相机位姿与内参。前者的生产标准是 COLMAP[2]：SIFT 提取[5] → 两两匹配与几何校验 → 增量式注册 → 反复束调整。这条链路鲁棒但慢，且其失败模式（视频序列上的注册分裂、弱纹理场景中断、多子模型需要人工合并）在工程上代价高昂。因此当 VGGT[6]、VGGT-Ω[7] 这类前馈网络以"单次前向、亚秒级、同时给出相机/深度/点图"的姿态出现时，"把 3DGS 前端换成网络"成为一个自然的工程设想。

这个设想在我们的生产链路上被证伪了。表 1 的第一行与第五/六行是同一批视频帧、同一份训练配置、同一台机器上的对照结果：VGGT 裸前向比 COLMAP 低 5.79 dB、VGGT-Ω 低 4.42 dB（口径 A）；若统一到 COLMAP 的最佳配置（各家自标定畸变后去畸变，见 §4.3），差距分别为 7.52 dB 与 5.08 dB。

关键问题是差距来自哪里。3DGS 的几何初始化有两个来源：位姿与点云。如果差距主要来自点云（网络点更密、含飘点、尺度不一致），那么改进网络点云是主线；如果来自位姿，那么必须在网络之外引入新的几何约束。我们用两组实验做了二分：

> 点云被排除。在同一份BA 精化位姿下，只把 3DGS 的初始化从三角化出的 SIFT 点云换成网络稠密点图，PSNR 从 25.79 dB 掉到 22.99 dB（Ω）与 25.10 dB 掉到 21.90 dB（VGGT）——点云质量确实影响质量，但它不是差距的来源，反而是网络前端的额外短板。反过来，COLMAP 只用 32693 个稀疏点就能得到 25.77 dB，说明 3DGS 对初始点的稠密度宽容、对几何一致性苛刻。
>
> 位姿被锁定。表 2 显示网络位姿与 COLMAP 参照的旋转残差中位数为 1.29°（VGGT）/0.54°（Ω）；我们人为把 COLMAP 位姿旋转扰动 0.6°/1.3°/2.6°，留出 PSNR 从 26.82 dB 掉到 20.29/17.55/16.34 dB（图 3 右）。这条敏感度曲线正好解释了网络前端的全部掉点幅度。

据此，本文不把精力放在"如何修网络点云"，而是研究一个更朴素的问题：能否用一次性的经典优化，把前馈网络的位姿与内参修到与 **COLMAP** 同一水平？答案是可以，而且做法极简：把 COLMAP 内部用于"已有位姿补点"的三角化与束调整搬到推理末尾，二维观测直接复用生产链路已经算好的 SIFT 匹配，网络位姿只作为初值。我们在国产 AI 加速器（天数 BI-V150S）平台上完整实现了该链路并给出成本分析。

本文贡献：

(1) 归因与量化（§5.2）：把前馈前端在 3DGS 上的 5–6 dB 损失归因到相机位姿与内参，并用扰动敏感度曲线、点云替换消融、尺度归一实验排除其他解释；指出网络从不输出畸变系数（$k_1 \equiv 0$）这一结构性缺陷无法靠"改用去畸变图像"规避，只能由束调整补出。

(2) 方法（路线 **A**，§**3**）：与官方前馈束调整的实质差别只在三维初值的来源——不再在查询帧像素处"查表"取网络稠密点图，而是用外部二维轨迹（**SIFT** 内点）在冻结的网络位姿下三角化、重新生成稀疏三维点，随后一次全局 BA（放开焦距与畸变）→ 点过滤 → 再 BA。网络稠密点图既不进入残差，也不作为 3DGS 初始化。它使 VGGT-Ω 与 COLMAP 打平（26.72 vs 26.82 dB），VGGT 残余 -1.13 dB。

(3) 对应关系的判决性实验（§**3.3**）：束调整的收益 100% 来自独立于网络的对应。用网络自点图自建 1.91×10^6 条观测做"自证式"BA，代价最高（291 s）、残差最低（0.256 px）、但位姿更歪（1.29°→1.43°）、k_1 连符号都错。这条结论直接否定了"给前馈网络加自监督 BA 精修"的朴素做法。

(4) 成本结构与诚实的净账（§**6**）：实测 COLMAP 的 BA 墙钟 97 s/占 mapper 53%（35 次全局 + ≈81 次局部调用，平均 1 s/次）；本文 BA 第 1 轮在 30 迭代即达到与 100/300 迭代逐位相同的解（57 s vs 142 s）；BA 墙钟线性于观测数（0.27/0.50/1.91 百万观测对应 68/117/291 s）。加 BA 之后前馈前端的速度优势基本消失。

(5) 可复现性（附录 **C**）：全部 20 档同配置干净重跑、逐视角数据、脚本与 COLMAP 4.0.4 rig/frame 二进制格式的踩坑记录（位姿真正存储在 `frames.bin` 而非 `images.bin`——我们在早期版本正是踩在此处而得到过一组"虚假打平"的结论，已撤回并在附录中说明识别方法）。

2 相关工作

2.1 经典结构恢复与束调整

COLMAP[2] 的增量式建图以"注册一帧、三角化、局部 BA，周期性全局 BA 与重三角化"为骨架；束调整的稀疏求解器与规模化策略见 Ceres[4] 与近实时 SfM 的 BA-in-the-loop[3]。二维对应来自 SIFT[5] 匹配加本质矩阵/基础矩阵 RANSAC 校验。本文把"三角化 + BA"这两个组件从建图循环中拆出来单独使用，保留了 COLMAP 的求解器与数据格式，但删掉了"增量注册 + 反复 BA"的整个循环。

2.2 前馈式重建

VGGT[6] 用交替注意力的 Transformer 一次前向预测相机、深度、点图与轨迹；VGGT-Ω[7] 进一步用单一稠密预测头、寄存器注意与自监督协议扩展规模。DUSt3R[8] 等成对/多视图点图方法属于同一大类。我们核查了 VGGT-Ω 论文与官方仓库：其推理阶段没有束调整，"bundle adjustment"仅出现在 §3.5.2 的数据标注管线中，且对应关系由外部算法（SIFT、SuperPoint+SuperGlue[9]、ALIKED+LightGlue[10]、VGGSfM Tracker[12]）提供，网络输出只在 RANSAC 内点不足时用于初始化。VGGT(v1) 官方 `demo_colmap.py` 的 `--use_ba` 同样是"网络给三维点 + 外部关键点/轨迹给对应 + pycolmap 求解"的三段式，并在注释中明确允许把 `pred_tracks` 换成 COLMAP/LightGlue/LoFTR[11] 的轨迹。本文的工作可视为把这条原本属于标注侧的链路搬到推理侧，并量化它对下游 3DGS 的价值。

2.3 3DGS 与几何先验

3DGS[1] 以各向异性高斯为基元做可微光栅化；Faster-GS[13] 在保持高斯数与质量不变的前提下优化其求解流程，本文的训练后端即其在本平台（天数 CoreX）的移植版本（移植要点见附录 B）。已有工作与我们的观察一致：3DGS 的致密化/剪枝阈值隐含依赖真实米制尺度与准确位姿，位姿误差会被致密化过程"用高斯糊住"，从而在训练视角看似拟合、留出视角崩塌——这正是我们观测到的"训练集 SSIM 最高而留出 PSNR 最低"现象。

3 方法

3.1 记号与问题设定

给定 N 帧图像（本文 N=83）。前馈网络输出每帧相机 $g_j=(R_j, t)$、内参 K_j（含焦距 f、主点 c_j，畸变恒为 0）与稠密点图 $\{X_j\}$、置信度 c_j。COLMAP 类管线则给出稀疏三维点集合与二维观测。束调整求解

$$\min_{\{K_j,R_j,t_j\},\{X_p\}} \sum_p \sum_{(j,u)\in T_p} \rho(|\pi(K_j,R_j,t_j,X_p)-x_{j,u}|^2), \quad (1)$$

其中 T_p 是第 p 个三维点的可见性轨迹，$x_{j,u}$ 是第 j 帧第 u 个二维特征观测，π 含畸变模型，ρ 为鲁棒核。式 (1) 的关键结构是：只有 $\boldsymbol{T_p}$ 里的观测产生残差。因此"用哪一来源的对应关系"完全决定了优化能拿到什么新信息。

3.2 路线 **A**：冻结位姿三角化 **+** 一次全局 **BA**

本文链路只有五步（下面 (a)–(e)，结构对照图 1）：

(a) 网络位姿导出。把 g_j, K_j 写成 COLMAP 稀疏模型。此处必须同时改写 `frames.bin`（COLMAP 4.0 的 rig/frame 重构后，位姿真正存储于此，`images.bin` 中的 (q, t) 为派生量；见附录 A）。

(b) 三角化。`colmap point_triangulator` 在冻结的位姿与内参下（`--clear_points 1 --refine_intrinsics 0`），把已有的 SIFT 二维匹配（`two_view_geometries` 表的 RANSAC 内点）成组射线求交，现场生成三维点与轨迹。这一步不改位姿（实测：三角化前后网络旋转残差逐位相同，均为 1.2912°）。

(c) 一次全局 **BA**。`bundle_adjuster` 放开位姿、焦距与畸变（`refine_focal_length=1, refine_extra_params=1`），迭代上限 30。

(d) 点过滤。`point_filtering --max_reproj_error 4 --min_tri_angle 1.5`。

(e) 再 **BA +** 再过滤。第二轮 50 迭代内即 `CONVERGENCE`。

与官方前馈束调整的实质差别：$\boldsymbol{X_p}$ 从哪里来 VGGT 官方的 `--use_ba`（`demo_colmap.py` + `np_to_pycolmap.py`）也是"外部二维轨迹 + pycolmap 求解"的三段式，但它喂给式 (1) 的三维初值 X_p 是按像素查表得来的：在查询帧的 2D 关键点 (u, v) 处直接取 `points_3d[img][v][u]`（网络输出的是稠密逐像素点图，故任意像素必可取到，不需要反投影搜索），其余帧的 2D 观测由外部追踪器补齐，再用 `Point2D(xy, point3D_id)` + `Track` 登记成关联图。这条做法的结构性后果是：X_p 的误差与深度头误差同分布，残差里不含任何独立于深度的几何信息，BA 无法把它拉回正确位置；其质量闸门也只有置信度阈值（`conf`>1.2）与一次投影预筛（8 px）两道软门。本文把这一步整体替换为三角化：X_p 由"冻结的网络位姿 + 外部 SIFT 内点的射线求交"生成，深度头完全不进入 X_p，并继承 COLMAP 的三道硬闸门（两视图 RANSAC 内点、`tri_min_angle` 射线夹角、`point_filtering` 的重投影误差/三角化角剔除）。网络在官方链路里是"被观测的对象"，在本文链路里只是"射线的摆放"，即优化初值。这一替换在表 1 中可单独计价：`omega`→`omegatri` 仅改变 X_p 的来源（位姿仍冻结）即得 +1.66 dB、`vggt`→`vggttri` 得 +1.01 dB；随后放开位姿与内参的 BA 再贡献 +2.78 dB/+4.11 dB。反向证据同样成立：把网络稠密点图 graft 进 3DGS 初始化反而损失 2.80/3.20 dB（§5.3）。

为什么不需要把二维观测"关联"到网络三维点 式 (1) 需要的是"三维点 ↔ 二维观测"的对应，而这些三维点不必是网络的点。步骤 (b) 在网络位姿张开的射线束里重新生成三维点，于是三维点与二维观测天生同标架、同尺度，无需任何配准；网络在这里的角色是射线的摆放（R_j, t_j, K_j），即优化初值，而非被观测的对象。反之，若要把网络稠密点与 SIFT 观测挂接（路线 C），需按 $|\pi(K_j, g_j, X_j)-k|<r$ 做互近邻挂接，此时信息量天花板由 SIFT 匹配数决定（本文 ≈3035 观测/帧），与路线 A 白送的观测数几乎相同，却把网络自身的深度误差（AbsRel

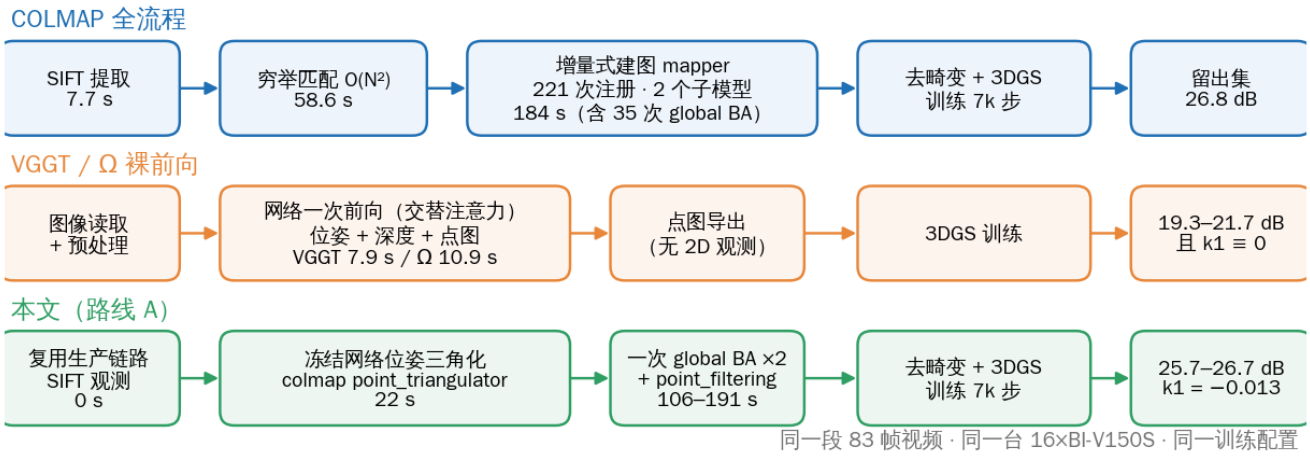


图 1 三条链路的结构与实测墙钟（83 帧，同一台 16×BI-V150S）。第一行 COLMAP 保留"穷举匹配 + 增量建图 + 反复 BA"；第二行前馈网络删掉对应关系与优化，也因此删掉了内参与畸变的估计能力；第三行本文只借 COLMAP 的"三角化 + 一次 BA"两个组件。

0.01–0.06）焊死在 X_p 的初值里，并额外引入约 25% 的 BA 尺度漂移需要处理。故未采纳。

网络稠密点图的正确位置 BA 结束后，我们用 BA 前后相机中心集合的 Umeyama 相似变换把网络点图整体搬进 BA 世界系，并以轨迹长度 *0* 写入模型（`track_len=0` ⇒ 零残差 ⇒ 在雅可比矩阵中连列都没有），仅作为 3DGS 初始化的候选。实验（§5.3）表明这条路不该走：它使 PSNR 下降 2.8–3.2 dB。

3.3 路线 B：自证式轨迹为何无效

为检验"是否必须有外部对应"，我们构造了对照组：以网络点图反投影出的三维点为 X_p，把每帧点图按相对深度互检（≤2%）与置信度分位阈值投影到其它帧，自建 ~1.91×10^6 条观测（202883 个点，均轨迹长 9.4）。这组观测与网络位姿完全自洽，初始代价 3.385 px（因写盘标架误差而偏高，但 BA 会自行消化），BA 后降到 0.256 px 并 `CONVERGENCE`——残差全场最低。然而位姿旋转残差从 1.2912° 升到 1.4296°，k_1 估成 +0.0010（真值 -0.0148，符号即错），留出 PSNR 只涨 0.05 dB（19.99→20.04，噪声级）。

机理解释：束调整是"用二维观测约束三维几何"的机制，其信息全部来自二维观测独立于当前三维与位姿估计的那部分。当观测由位姿与深度自身投影生成时，目标函数在当前解处已近乎最优，梯度只把解往"更自洽"而不是"更正确"的方向推；而自洽性本身对尺度、朝向乃至整体畸变都不敏感（gauge 自由度），于是优化反而放大了系统性偏差。工程结论：任何"网络自监督 BA"都必须引入独立对应（SIFT/LoFTR/光流/IMU/帧序先验）。

3.4 成本结构：一次性 BA vs 反复 BA

表 3 与图 7 给出三种"BA 很贵"的不同含义。（i）*COLMAP* 的 *BA* 贵在被反复调用：默认 mapper 184 s，把 BA 迭代上限设为 0/1 并放宽函数容差后为 87 s，两者差 ≈97 s 即 BA 在 mapper 内的真实占比（53%），来自 35 次全局 BA 与约 81 次局部 BA 的累计，平均 1 s/次；同时平均重投影从 1.648 px 降到 0.565 px，说明这 97 s 买到的是几何精度本身。（ii）我们的单次 *BA* 反而比整个*"无 BA 的 mapper"*更久（136 s vs 87 s），因为它第一轮就作用在全部 503770 条残差上。（iii）但我们的调用次数是 2，且成本线性于观测数（0.27/0.50/1.91 百万观测 →68/117/291 s），因此规模增长可预测，且不存在"多子模型/注册失败重试"这一不可预算项。

4 实验设置

4.1 平台与实现

全部实验在 `root@10.9.11.38` 的一台 16× 天数 BI-V150S（每卡 32GB，`ixsmi` 监控）服务器上完成，软件栈为 CoreX-5.0.0（CUDA 10.2 兼容层）+ PyTorch 2.10（CoreX 构建）。SfM 工具为自编译 COLMAP 4.0.4（Commit 65e6439e，CUDA/ivcore11）；3DGS 训练后端为 nerficg 框架内的 Faster-GS[13]（本平台移植见附录 B）；前端为官方 VGGT-1B（bf16，518 裁剪）与 VGGT-Ω-1B（fp32，512 balanced）。全部评测指标中 LPIPS 使用 VGG 权重。

4.2 数据、留出协议与训练配置

数据为一段行车视频的抽帧序列 `c6183bb30c62`，83 帧 1920×1080。训练分辨率缩放 0.25（480×270）；按文件名每 8 帧留 1 帧作测试（`TEST_STEP=8`），即 11 张留出、72 帧训练；训练 7000 步、`RANDOM_SEED=0`、其余超参取默认。所有 20 个档位共用同一批图像、同一份训练配置与同一随机种子，只有**"位姿*/*内参*/*初始点云从何而来"**这一个变量。

4.3 两种质量口径

前馈网络输出 $k_1 \equiv 0$，而 COLMAP 的 SIMPLE_RADIAL 解给出 k_1=-0.0148。如果所有档位都用 COLMAP 的去畸变图像，那么网络档位的像素与其自身模型假设不一致（图像已被 COLMAP 的 k_1 弯过一次）；如果都用原始畸变图，则网络档位缺少畸变项。为避免口径偏袒，我们两种都报：口径 **A**：全部使用原始畸变图像（SIMPLE_RADIAL 模型，1920×1080）；口径 **B**：各档用自己标定的 k_1 做 `image_undistorter` 去畸变（网络档位用其 BA 后估出的 k_1），即 COLMAP 生产链路的真实口径。本文标题性结论在两种口径下都成立，且口径 B 更能反映生产可比性。

4.4 数据卫生：一次干净矩阵重跑

早期结果存在两处归属风险：（1）部分档位的输出目录同名（配置里的 `MODEL_NAME` 未随档位改写）；（2）数据集目录在中途被重建过，导致同名档位在前后两次评测中指向不同数据。为此我们重跑了整个矩阵：每档独立 `MODEL_NAME`、每档独占一张 GPU、同一波次并发、逐档独立日志，并把 PSNR/SSIM/LPIPS、逐视角 PSNR、高斯数、墙钟一并落盘。本文所有数字来自这一次干净重跑；重跑与独立早期结果的偏

离均在 ±0.3 dB 内（种子噪声水平）。

5 结果

5.1 主结果

表 1 与图 2 给出全部档位。三点观察：

（**1**）前馈前端确实掉得多。口径 A 下 VGGT 裸前向 19.98 dB、VGGT-Ω 21.35 dB，COLMAP 参照 25.77 dB；口径 B 下分别为 19.30/21.74 dB 对 26.82 dB。Ω 稳定优于 VGGT（其位姿残差本就更小：0.54° vs 1.29°）。

（**2**）一次性 **BA** 把差距基本抹平。口径 A：Ω 从 21.35 dB 升到 25.79 dB（+4.44 dB），反超 COLMAP 参照 0.02 dB；VGGT 从 19.98 dB 升到 25.10 dB（+5.12 dB），残余 -0.67 dB。口径 B：Ω 21.74→26.72 dB（+4.98 dB），与 COLMAP 26.82 dB 差 0.10 dB，而 LPIPS 更优（0.198 vs 0.203）、SSIM 基本相同（0.875 vs 0.877）；VGGT 19.30→25.69 dB，残余 -1.13 dB。

（**3**）三角化与 **BA** 的贡献可分离。只三角化不 BA（位姿冻结）：Ω +1.66 dB、VGGT +1.01 dB——这部分来自"用真实 SIFT 点云替换网络稠密点云"；BA 的净贡献则是 Ω +2.78 dB、VGGT +4.11 dB。可见位姿/内参修复才是主收益来源。

表 1 口径 A（原始畸变图像）下的留出集质量。83 帧、0.25 分辨率、7000 步、11 张留出、seed=0，全部 20 个档位同一次干净矩阵重跑。

档位	前端配置	PSNR	SSIM	LPIPS
cmap_raw	COLMAP 全流程	25.77	0.837	0.234
omega	Ω 裸前向（网络点云）	21.35	0.674	0.326
omegatri	Ω + 三角化	23.01	0.741	0.290
omegatriba	Ω **+** 三角化 **+ BA**（本文）	**25.79**	**0.843**	**0.219**
omegatriba_vgpts	Ω + BA，但用网络稠密点云	22.99	0.766	0.264
vggt	VGGT 裸前向（网络点云）	19.98	0.596	0.427
vggttri	VGGT + 三角化	20.99	0.641	0.372
vggttriba	**VGGT +** 三角化 **+ BA**（本文）	**25.10**	**0.811**	**0.253**
vggttriba_vgpts	VGGT + BA，但用网络稠密点云	21.90	0.709	0.341
vggtgrid	路线 B：自证轨迹（无 BA）	19.99	0.600	0.407
vggtgridba	路线 B：自证轨迹 + BA	20.04	0.601	0.403

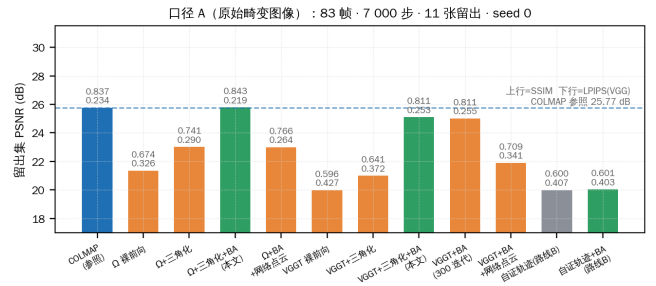


图 2 口径 A 全部 12 个非消融/消融档位的留出集 PSNR（柱顶两行分别为 SSIM 与 LPIPS）。绿色为本文路线 A，橙色为前馈前端，灰色为路线 B（自证轨迹）。

5.2 位姿与内参：差距的直接来源

表 2 以 COLMAP 模型为参照（Umeyama 相似变换吸收尺度与刚体自由度后统计不可吸收残差，轨迹对角线 10.782 m）。BA 之前，Ω 的旋转残差中位数 0.5404°、VGGT 1.2912°，而"COLMAP 与自身另一种解之差"仅 0.04° 量级，可作为噪声地板。BA 之后：Ω 降到 0.0701°（降 7.7×，已接近噪声地板），VGGT 降到 0.3212°（降 4.0×）；光心残差（占轨迹对角线）0.395%→0.096%、0.579%→0.291%；平均重投影 1.443 px→0.386 px、1.629 px→0.372 px（COLMAP 参照 0.565 px——我们的解在重投影意义上甚至比它更好，因为参照含远端外点）。

内参被顺手修好，这是 **PSNR** 的另一半来源。焦距：Ω 872.09→852.55、VGGT 872.34→856.04，参照 850.73（网络原本偏长 +2.5%）；畸变 k_1：0→-0.0133 / 0→-0.0127，参照 -0.0148。这解释了为什么"改用去畸变图像"救不了裸网络档位（表 1 的 `vggtu/omegau` 反而更低）：网络不知道有畸变，去畸变只能由别人的 k_1 完成，而那个 k_1 与网络位姿不自洽。只有 BA 能同时给出自洽的 (f, k_1) 对。

位姿敏感度实验。为把"*dB* 每度"量化，我们对 COLMAP 解注入人为旋转扰动并重训（口径 B）：0° 26.82 dB、0.6° 20.29 dB、1.3° 17.55 dB、2.6° 16.34 dB（图 3 右）。小扰动段斜率约 -10.9 dB/°。把各档位的实测旋转残差投影到这条曲线上，可以预测其掉点幅度：Ω（0.54°）约 -5.9 dB，实测 -5.47 dB（口径 B，21.74 vs 26.82）；VGGT（1.29°）约 -13 dB，实测 -7.52 dB——VGGT 实测优于预测，说明网络误差是相干的（整体偏转/尺度偏差），部分可被 3DGS 的致密化吸收，而人为扰动是逐帧独立的，更毒。这也解释了为什么"一次全局 BA"就够：相干误差正是低维参数化 BA 最擅长消除的成分。

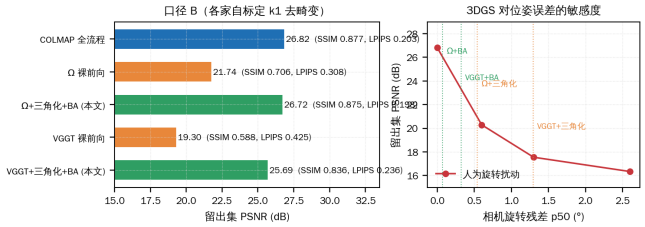


图 3 左：口径 B（各家自标定 k_1 去畸变）下的留出集质量，本文链路 Ω 与 COLMAP 全流程相差 0.10 dB。右：把 COLMAP 位姿人为旋转扰动的敏感度曲线（圆点），以及各档位实测旋转残差与质量（竖线）；两条轴在同一量级上相互印证。

5.3 消融：什么有用、什么有害

把网络稠密点云接回来是有害的。在完全相同的 BA 位姿/内参下，仅把 3DGS 初始化从三角化 SIFT 点云换成网络稠密点图（`omegatriba_vgpts`、`vggttriba_vgpts`），PSNR 从 25.79 掉到 22.99 dB（-2.80）与 25.10 掉到 21.90 dB（-3.20）。注意这两个档位的位姿与最优档位完全相同——纯粹是点云造成的。这与 60 帧受控实验中"Ω 训练集 SSIM 最高但留出 PSNR 最低"的观察一致：稠密网络点带来的是过拟合能力，不是泛化能力。

自证式轨迹 **BA** 无效。路线 B（`vggtgrid/vggtgridba`）：19.99→20.04 dB，位姿反而从 1.2912° 恶化到 1.4296°，代价虽然收敛到全场最低的 0.256 px（图 4 右）。

BA 多迭代没有收益。把第 1 轮上限从 100 提到 300（`vggttrilong`），最终代价 0.379011 px 与 100 迭代逐位相同，模型侧旋转残差仍是 0.3212°，PSNR 25.02 vs 25.10 dB（噪声）。反之把上限降到 30，解与 100 迭代逐位相同（旋转差 $\le 6\times10^{-6}$°、光心差 $\le 5.8\times10^{-7}$、f/k_1 完全一致）而墙钟省 85 s。残余的 -0.67 dB（VGGT，口径 A）是信息极限而非迭代极限：要再进一步只能增加独立对应（稠密匹配器、帧序/IMU 先验）。

表 2 位姿/内参残差（参照 = COLMAP 模型，Umeyama 吸收尺度与刚体自由度后的不可吸收残差；轨迹对角线 10.782m）。

模型	阶段	光心残差%	旋转 **p50(°)**	旋转 **p95(°)**	重投影**(px)**	***f***	k_1
vggt	网络裸输出	0.579	1.2912	2.464	—	872.34	0
vggttri	+ 三角化（位姿冻结）	0.579	1.2912	2.464	1.629	872.34	0
vggttriba	+ 一次 global BA	0.291	0.3212	0.665	0.372	856.04	-0.0127
omega	网络裸输出	0.395	0.5404	1.573	—	872.09	0
omegatri	+ 三角化（位姿冻结）	0.395	0.5404	1.573	1.443	872.09	0
omegatriba	+ 一次 global BA	0.096	0.0701	0.199	0.386	852.55	-0.0133
cmap_raw	COLMAP 参照（噪声地板）	0.040	0.040	—	0.565	850.73	-0.0148
vggtgridba	路线 B（自证轨迹 BA）	—	1.4296（变差）	—	0.256	865.63	+0.0010

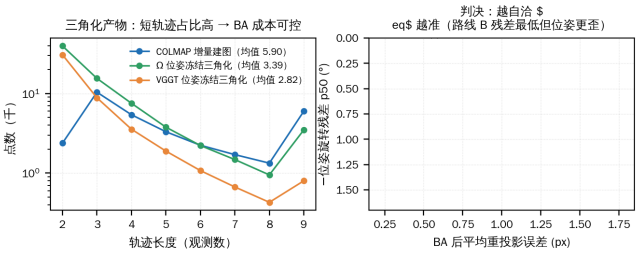


图 4 左：三角化产物的轨迹长度分布（对数纵轴）。本文三角化点云中位轨迹长仅 2、均值 3.39，比 COLMAP 增量建图（中位 4、均值 5.90）更"瘦"，这既是 BA 成本可控的原因，也是残余差距的来源之一。右：BA 残差与位姿残差的关系——残差最低者（路线 B）位姿最歪，说明"更自洽"不等于"更正确"。

5.4 逐视角行为与定性

图 5 给出 11 张留出视角的逐视角 PSNR。六个档位的曲线形状一致（视角 0 最易、视角 6 最难），但间距随难度增大：在最难视角上 COLMAP 23.29 dB、Ω+BA 24.40 dB、Ω+三角化 22.03 dB、Ω 裸 19.18 dB、VGGT 裸 17.80 dB。留出视角离训练轨迹越远，位姿/内参误差的杠杆越大——这与式 (1) 的几何一致（外推视角的像素位移 $\propto f\cdot\Delta\theta$，故 f 偏长与 θ 偏差会同向叠加）。图 6 的定性对比同样显示：网络裸前向的飘点与"糊墙式"过曝在 BA 后基本消失，Ω+BA 与 COLMAP 的渲染在难视角上已难以分辨。

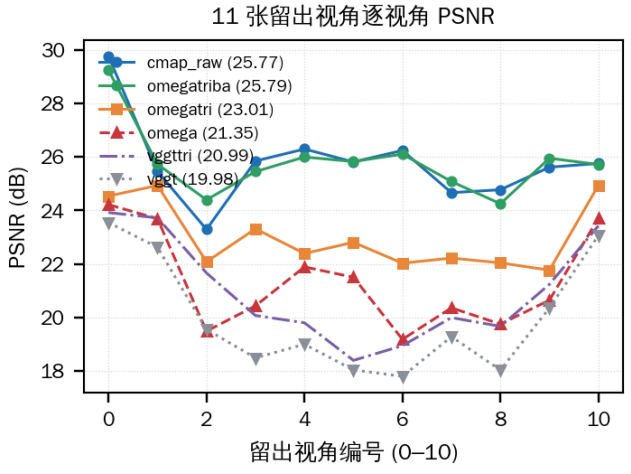


图 5 逐视角 PSNR（11 张留出）。

6 耗时与成本

6.1 BA 到底贵在哪里

表 3 BA 成本实测（同一 `database.db`、同一容器、空载、`OMP_NUM_THREADS=8`）。BA 墙钟近似线性于观测数：0.27M→68s、0.50M→117s、1.91M→291s。

跑法	墙钟**(s)**	**Final cost(px)**	备注
colmap mapper（默认 BA）	184	0.565	2 个子模型 / 83 图 / 32690 点
mapper（关掉 BA 迭代）	87	1.648	83 图 / 37315 点
⇒ mapper 内 BA	≈97 (53%)	—	35 次 global + ≈81 次 local，≈1s/次
本文 BA 第 1 轮（30 迭代）	57	0.33855	与 60/100 迭代解逐位相同
本文 BA 第 1 轮（100 迭代）	142	0.33855	NO_CONVERGENCE
本文 BA 第 1 轮（300 迭代）	171.6	0.37900	PSNR 25.08 vs 24.97：噪声
point_filtering + 第 2 轮 BA(50)	24	0.31747	CONVERGENCE（18 迭代）
自证轨迹 BA（1.91M 观测）	291	0.256	CONVERGENCE，但位姿更歪

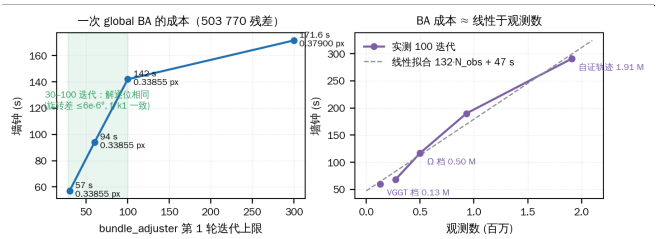


图 7 左：第 1 轮全局 BA 的迭代上限与墙钟；30、60、100 迭代给出逐位相同的解（阴影区），300 迭代无收益。右：BA 墙钟随观测数线性增长。

表 3 的 A/B 实验（同一 `database.db`、同一容器、空载、8 线程）说明：COLMAP 的 BA 在 mapper 内占 ≈97 s（53%），但它是 35 次全局 + 约 81 次局部调用的累计，平均单次仅 1 s。注意 mapper 内部把 `print_summary` 置为 `false`[2]，日志里看不到 BA 报告，这也是"BA 最耗时"长期无法从日志证实的原因；COLMAP 4.0.4 的 mapper BA 亦为同步串行，不与注册循环重叠。

我们的做法是把 BA 降级为推理末尾的两次全局求解：第 1 轮（30 迭代）57 s、过滤 3 s、第 2 轮（50 上限，实际 18 迭代 `CONVERGENCE`）21 s，加三角化 22 s 合计 ≈106 s；若第 1 轮仍用 100 迭代则 ≈191 s。成本线性于观测数（图 7 右），因此可通过 `- -Mapper.tri_ignore_two_view_tracks 1`（丢弃短轨迹）或改用 `sequential_matcher` 降低观测规模来进一步压缩。

6.2 端到端净账



图 6 定性对比（3 个留出视角 × 6 档，480×270；每格右下角为该视角 PSNR）。第一行最难视角之一：网络裸前向出现明显的地面拉丝与车身重影，三角化改善结构，BA 后与 COLMAP 参照基本一致。

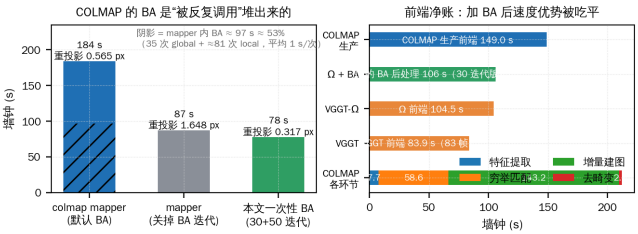


图 8 左：BA 在 COLMAP 内部占比的 A/B 实测，以及与本文一次性 BA 的对比（柱下为重投影误差）。右：前端各环节墙钟。

图 8 右给出前端净账（83 帧）：COLMAP 生产脚本 148.96 s；VGGT 前端 83.90 s，加 BA 后 ≈194 s（30 迭代版 ≈144 s）；Ω 前端 104.50 s，加 BA 后 ≈296 s（30 迭代版 ≈211 s）。也就是说，在 **COLMAP** 能顺利建图的素材上，**"**用网络省时间**"**这个动机在加上 **BA** 之后基本不成立。训练侧不受前端影响（7000 步单卡 159–203 s，点数越少越快），三链路端到端（前端 + 训练 + 渲染 + 评测）分别为 COLMAP 537.19 s、VGGT 465.74 s、Ω 554.23 s。

那么网络前端的价值在哪里？三点：（i）全帧注册：网络 83/83 全注册，而 mapper 在同一数据上产生 2 个子模型、221 次注册尝试（其中失败重试的成本不计入成功路径）；（ii）成本可预算：我们只有"匹配 + 一次 BA"两项确定成本，没有"注册失败、分裂、人工合并、重跑"这一项；（iii）初值质量：网络给出相干型偏差的初值，使"一次全局 BA"成为充分操作，而 COLMAP 必须靠增量循环自己把初值找出来。反过来，如果素材本身能被 COLMAP 顺利处理，网络前端的净收益接近 0——这是我们希望明确说清的边界。

7 讨论与局限

结论的适用范围。本文只有一段 83 帧行车视频（弱纹理地面 + 多车遮挡）、7000 步训练。绝对 PSNR 不可与公开基准直接比较（分辨率与步数都远低于 3DGS 论文口径），但档位之间的差在同一配置下具有可比性，且 ±0.3 dB 以内的差我们一律视为噪声。口径 B 下 VGGT 残余 -1.13 dB 说明单次 BA 对初值更差的 VGGT 并未完全收敛到 COLMAP 水平。

与 **VGGT-**Ω 论文的关系。Ω 的精度指标（相机 AUC 等）是网络裸输出，论文中的 BA 属于数据标注侧且由外部对应驱动 [7]。因此本文不是"发明论文没有的东西"，而是把论文放在标注阶段的经典组件搬到推理侧，并证明它对下游 3DGS 是决定性的。这也暗示了一个产品含义：前馈网络的公开评测口径（AUC、AbsRel）与下游可重建性之间存在缝隙——$k_1 \equiv 0$ 就 是最典型的缝隙，本文的 +1.2 dB（口径 A→B 时本文链路的 增益）几乎全部来自它。

仍未解决的问题。（1）网络稠密点图在 3DGS 初始化上仍无用（-2.8 至 -3.2 dB），需要飘点治理或"稠密几何当先验而非观测"（BA 外加软约束 $w|X\text{-}proj(X)|^2$）；（2）本文复用了生产链路的 SIFT 数据库，虽然对 COLMAP 而言是免费午餐，但对"完全不想跑匹配"的场景，需另找独立对应来源（LoFTR[11]/RAFT 类稠密匹配、或帧序与 IMU 先验）；（3）动态目标（视频中的行驶车辆）在轨迹里构成系统性外点，本文靠 `point_filtering` 与鲁棒核压住，但没有专门建模。

8 结论

在国产化 AI 加速器平台上，我们把 COLMAP 的"三角化 + 束调整"两个组件从增量式建图循环中剥离出来，用作前馈重建前端（VGGT / VGGT-Ω）输出的一次性后处理：冻结网络位姿做三角化以重建与外部 SIFT 观测一致的三维点集，再放开位姿、焦距与畸变做一次全局 BA，夹一轮点过滤后再次 BA。仅此五步即可把前馈前端在 3DGS 上的 4.4–7.5 dB 损失收回至 0.10 dB（Ω）与 1.13 dB（VGGT），并把网络从不估计的畸变系数从无到有标定出来。我们同时给出该做法的两个必要条件（对应关系必须独立于网络；网络稠密点云不应进入残差、也不应作为 3DGS 初始化）与其代价（前端速度优势基本消失）。对希望用前馈网络替换 SfM 前端的工程实践，本文的建议是：把网络当**"**好的初值生成器**"**，把经典 **BA** 留在推理末尾，而不是指望网络端到端替代优化。

[1] Kerbl B, Kopanas G, Leimkühler T, Drettakis G. 3D Gaussian splatting for real-time radiance field rendering[J]. ACM Transactions on Graphics, 2023, 42(4): 139:1–139:14.

[2] Schönberger J L, Frahm J M. Structure-from-motion revisited[C]//Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR). 2016: 4104–4113.

[3] Schönberger J L, Preisach C, Niemasz K, et al. Structure-from-motion with incremental mapping and bundle adjustment in the loop[C]//Eur. Conf. Computer Vision (ECCV). 2020.

[4] Agarwal S, Mierle K, Szeliski R, et al. Estimating the epipolar geometry / Bundle adjustment in the large: a scalable modern implementation[C]//Eur. Conf. Computer Vision (ECCV). 2010.

[5] Lowe D G. Distinctive image features from scale-invariant keypoints[J]. International Journal of Computer Vision, 2004, 60(2): 91–110.

[6] Wang J, Chen M, Karaev N, Vedaldi A, Rupprecht C, Novotny D. VGGT: Visual geometry grounded transformer[C]//Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR). 2025: 5942–5954. arXiv:2503.11651.

[7] Wang J, Chen M, Zhang S, Karaev N, Schönberger J, Labatut P, Bojanowski P, Novotny D, Vedaldi A, Rupprecht C. VGGT-Ω[EB/OL]. arXiv:2605.15195, 2026.

[8] Wang S, Leroy V, Cabon Y, et al. DUSt3R: Geometric 3D vision made easy[C]//Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR). 2024.

[9] Sarlin P E, Cadena C, Siegwart R, Dymczyk R. SuperGlue: Learning feature matching with graph neural networks[C]//Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR). 2020.

[10] Lindenberger P, Arpinin S, Sarlin P E, et al. LightGlue: Local feature matching at light speed[C]//Proc. IEEE/CVF Int. Conf. Computer Vision (ICCV). 2023.

[11] Sun J, Shen Z, Wang Y, et al. LoFTR: Detector-free local feature matching with transformers[C]//Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR). 2021.

[12] Lin H, Peng S, Sun H, et al. VGGSfM: Visual geometry grounded deep structure from motion[C]//Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR). 2024.

[13] Hahlbohm F, Franke L, Eisemann M, Magnor M. Faster-GS: Analyzing and improving Gaussian splatting optimization[EB/OL]. arXiv, 2026.

附录 **A COLMAP 4.0.4** 二进制格式与三个坑

坑 **1**：位姿真正存储在 `frames.bin`。4.0 引入 rig/frame 重构，`bundle_adjuster/point_triangulator` 读取 `rigs.bin` + `frames.bin`，其中每条 frame 记录为 `frame_id:i32 | rig_id:i32 | 7×f64(`q_w`, `q_x`, `q_y`, `q_z`, `t_x`, `t_y`, `t_z`) | 20 B` 尾部（本例记录长 84 B；解析时用 `len(body)//n` 反推记录长更稳），`images.bin` 中的 (q, t) 只是派生量。我们早期版本的导出脚本只改了 `images.bin`，`frames.bin` 原样拷贝 COLMAP 模板 ⇒ 后续三角化/BA 一直在用 COLMAP 自己的位姿，网络位姿被完全忽略，并因此得到过"Ω+BA 与 COLMAP 打平"的虚假结论。识别方法：对导出模型与网络原始模型做位姿差统计——若逐位为 0.0000°，说明网络位姿根本没写进去。坑 **2**：`cameras.bin` 的 **model_id** 编号与 **3.x** 不同（实测 `1=PINHOLE`(4 参数)、`2=SIMPLE_RADIAL`(4 参数)、`0=SIMPLE_PINHOLE`(3 参数)），按 3.x 编号解析会把 (f_x, f_y, c_x, c_y) 整体错一位。稳妥做法：按文件大小反推参数个数。坑 **3**：手写模型的 `error` 字段不可用于自检。`model_analyzer` 的平均重投影读的是存储的 `error` 字段（手写为 0），自检必须用 `bundle_adjuster - -max_num_iterations 1` 报出的 *Initial cost*。此外 `bundle_adjuster/point_filtering` 的 `output_path` 必须预先存在，否则报错并在后续 `point_filtering` 处 core dump；`point_filtering` 的选项不带 `PointFiltering.` 前缀。

附录 **B Faster-GS / nerficg** 在 **CoreX-5.0** 上的移植要点

本实验的训练后端是 nerficg 内的 Faster-GS 在天数 CoreX-5.0 上的移植：(i) 排序内核 `sort_radix_by_key` 替换为 `at::sort(stable=true)` 两次调用；(ii) `glm::fast*` 在 ivcore11 下退化为 `std::` 版本（约慢 4.5×，实测非瓶颈，故不做位级近似以免破坏黄金比对）；(iii) 关闭 `--use_fast_math`，并要求训练与评估全程一致；(iv) 修复 autograd 尾部累加（`acc grad += grad`）与 ivcore11 的 `numeric_limits<>{::max()}/{::lowest()}`、`::nanf`；(v) morton CUDA kernel 在本平台性能极差，是本仓库早期"nerficg 训练要几个小时"的主因之一。移植后的训练吞吐：7000 步单卡 137–222 s。需要提醒的是：本平台的任何精度/崩溃问题都应先用 `CUDA_VISIBLE_DEVICE` 单卡复现排除并发干扰。

附录 **C** 复现要点与脚本清单

`code/` 目录（与容器内 `/root/cmp_test/wzong_eval/bin/` 一致）：`run_matrix.sh`（20 档矩阵，每档独立 `MODEL_NAME`/独立 GPU）、`run_ba_arm.sh`（路线 A 一键：导出 → 三角化 → BA → 过滤 → BA → 过滤 → graft → 配置）、`run_undist_arm.sh`（口径 B）、`run_one.sh`（训练 + 留出评测）、`colmap_frames.py`（`frames.bin`/`cameras.bin` 读写与位姿改写）、`mk_vggt_sparse2.py`（网络位姿 → COLMAP 模型）、`mk_grid_tracks.py`（路线 B 自证轨迹）、`mk_ba_plus_vgpts.py`（Sim3 graft 网络点云）、`geom_diff.py`（Umeyama 位姿/内参残差）、`cmpba2.py`（两份 BA 解逐位对拍）、`ba_vs_mapper.sh`/`ba_ab.sh`（BA 成本 A/B）、`perview.py`（逐视角 PSNR）、`paper_meta.py`（元数据与轨迹长度统计）。数据与图表生成：`tools/make_figs.py`。关键命令：

```
colmap point_triangulator --database_path $DB --image_path $IMG \
  --input_path $M --output_path $M --clear_points 1 \
  --refine_intrinsics 0 --Mapper.tri_min_angle 0.5 \
  --Mapper.tri_ignore_two_view_tracks 0 --Mapper.num_threads 8
colmap bundle_adjuster --input_path $IN --output_path $OUT \
  --BundleAdjustment.refine_focal_length 1 \
  --BundleAdjustment.refine_extra_params 1 \
  --BundleAdjustmentCeres.max_num_iterations 30
colmap point_filtering --input_path $IN --output_path $OUT \
  --max_reproj_error 4 --min_tri_angle 1.5   # 注意无 PointFiltering. 前缀
```

附录 **D** 全部 **20** 个档位的完整结果

表 4 给出本文全部档位（含口径 A/口径 B、消融档与位姿扰动档）的完整留出集指标，便于核对正文中任何一处差值。表中"三维初值来源"一列即本文与官方前馈束调整的分歧点：官方为"查询帧像素处查表取网络稠密点图"，本文为"外部 SIFT 内点在冻结位姿下三角化"。

表 4 全部 20 个档位的完整留出集结果（同一次干净矩阵重跑：83 帧、训练分辨率缩放 0.25、7000 步、`TEST_STEP=8` 留出 11 张、`RANDOM_SEED=0`；每档独立 `MODEL_NAME` 与独立 GPU）。口径 A 使用原始畸变图像，口径 B 各档用自身标定的 k_1 去畸变。加粗为本文链路与 COLMAP 参照。最后三行是人为旋转扰动的敏感度档位（口径 B，非链路对比档）。

档位	前端配置	三维初值来源	**PSNR**	**SSIM**	**LPIPS**	高斯数
口径 **A**（原始畸变图像）						
cmap_raw	COLMAP 全流程（参照）	COLMAP SIFT+BA	**25.77**	0.837	0.234	626616
omega	Ω 裸前向（网络点图）	无（网络点图）	21.35	0.674	0.326	697889
omegatri	Ω + 三角化（位姿冻结）	SIFT 三角化	23.01	0.741	0.290	651023
omegatriba	Ω + 三角化 + BA（本文）	SIFT 三角化+BA	**25.79**	0.843	0.219	634702
omegatriba_vgpts	Ω + BA，但用网络点图初始化	SIFT 三角化+BA	22.99	0.766	0.264	715366
vggt	VGGT 裸前向（网络点图）	无（网络点图）	19.98	0.596	0.427	635674
vggttri	VGGT + 三角化（位姿冻结）	SIFT 三角化	20.99	0.641	0.372	627185
vggttriba	VGGT + 三角化 + BA（本文）	SIFT 三角化+BA	**25.10**	0.811	0.253	—
vggttrilong	VGGT + 三角化 + BA，第 1 轮 300 迭代	SIFT 三角化+BA	25.02	0.811	0.255	622666
vggttriba_vgpts	VGGT + BA，但用网络点图初始化	SIFT 三角化+BA	21.90	0.709	0.341	695987
vggtgrid	路线 B：自证轨迹（无 BA）	网络点图自投影	19.99	0.600	0.407	621609
vggtgridba	路线 **B**：自证轨迹 **+ BA**	网络点图自投影	**20.04**	**0.601**	**0.403**	**—**
口径 **B**（各家自标定 k_1 去畸变）						
cmap	COLMAP 全流程（去畸变，参照）	COLMAP SIFT+BA	**26.82**	0.877	0.203	477211
omegau	Ω 裸前向（去畸变）	无（网络点图）	21.74	0.706	0.308	665745
omegatribau	Ω + 三角化 + BA（去畸变，本文）	SIFT 三角化+BA	**26.72**	0.875	0.198	—
vggtu	VGGT 裸前向（去畸变）	无（网络点图）	19.30	0.588	0.425	573660
vggttribau	VGGT + 三角化 + BA（去畸变，本文）	SIFT 三角化+BA	**25.69**	0.836	0.236	—
cp06	扰动实验：COLMAP 位姿旋转 0.6°	COLMAP SIFT+BA	20.29	0.584	0.399	543342
cp13	扰动实验：旋转 1.3°	COLMAP SIFT+BA	17.55	0.505	0.503	425435
cp26	扰动实验：旋转 2.6°	COLMAP SIFT+BA	16.34	0.482	0.561	340567